

휴먼인더루프(human-in-the-loop) 시스템과 형사책임

오 병 두*

목 차

- I. 시작하며
- II. 휴먼인더루프 시스템에서
- III. 휴먼인더루프 시스템에서 인간의 형사책임
- IV. 맺으며

I. 시작하며

구 소련의 공군 중령이자 방공군 당직사령이었던 스타니슬라프 페트로프 (Stanislav Yevgrafovich Petrov, 1939-2017)는 “세상을 구한 사람”(The Man who Saved the World)으로 불린다.¹⁾ 핵미사일 경보를 판단하는 비밀통제센터의 당직사관이었던 그는 1983년 9월 26일, 레이더 조기 경보 시스템에 미국의 ICBM 5발이 구 소련을 향해 발사되었다는 경보음을 확인하였다. 당시 당직사관의 업무 프로토콜(protocol)에 따르면, 최고지휘관에서 보고하여 즉시 보복타격을 위한 핵미사일 발사를 권고해야 하였다. 그러나 그는 이를 조기 경보 시스템의 오작동으로 인한 잘못된 경보로 판단하였고, 또 그렇게 보고하였다. 미사일의 발사 여부가 확인될 때까지 23분의 숨 막히는 시간이 지났다. 사후적으로는 확인된 바에 따르면, 인공위성이 구름 위에 반사된 태양 광을 오인한 것이었다고 한다. 결국 “그는 옳았고, 제3차 세계대전은 가까스로 피하게 되었다. 루프에 사람이 없었다면(if there had been no human in the loop) 어떤 일이 벌어졌을지 우리는 알지 못한다.”²⁾

* 홍익대학교 법과대학 교수

1) 이하의 설명은 “Soviet officer who averted cold war nuclear disaster dies aged 77”, The Guardian, 2017. 9. 18, <<https://www.theguardian.com/world/2017/sep/18/soviet-officer-who-averted-cold-war-nuclear-disaster-dies-aged-77>>, 최종검색: 2026. 6. 15.

스타니스라프 페트로프의 사례는 인공지능(Artificial Intelligence, AI)에 의한 자율형 살상 무기의 ‘신뢰성’(reliability) 문제를 상징적으로 보여주는 대표적인 사건으로 꼽힌다.³⁾ 동시에 이는 인간과 인공지능의 협업모델로서 인간의 관여를 강조하는 휴먼인더루프(human-in-the-loop, HITL)의 필요성을 보여주는 사례이기도 하다.⁴⁾

최근 생성형 인공지능(Generative AI, GenAI)이 일상생활과 업무에서 널리 활용되면서 일종의 ‘오작동’이라고 할 수 있는 ‘환각(Hallucination)’ 현상이나 편견의 문제가 빈번하게 이슈가 되고 있다. 위와 같은 ‘사고’의 위험성도 함께 커지고 있다. 이에 대응하여 인공지능 시스템에 인간이 개입하는 휴먼인더루프에 대한 관심도 높아지고 있다.⁵⁾ 휴먼인더루프 시스템이 중시되는 이유는 인공지능이 발전할수록 인간의 삶에 미치는 영향과 위험성이 증가하고 그에 비례하여 해당 시스템의 안전성과 정확성 및 효율성을 담보하기 위해 인간의 역할이 더욱 강조되기 때문이다.⁶⁾

인간의 역할이 강조되면서, 인공지능의 활용과 결부된 인간의 법적 책임 역시 동반하여 강화되는 상황에 놓이면서, 그 법적 중요성이 새롭게 부각된다. 여기에서 이 글은 휴먼인더루프 시스템과 관련한 형사책임 문제를 이 시스템을 구성하는 인간과 인공지능 시스템을 중심으로 다루고 한다. 먼저, 휴먼인더루프의 의미 그리고 규범적 검토의 필요성을 확인하고자 한다(Ⅱ. 1.). 다음으로, 인공지능의 독자적인 형사책임 주체성 논의를 점검하고(Ⅱ. 2.), 휴먼인더루프 시스템에서는 인공지능의 형사책임 주체성 논의가 어떻게 달라지는지를 살펴볼 것이다(Ⅱ. 3.). 끝으로, 이상의 논의를 토대로 휴먼인더루프 시스템에 관여한 인간과 인공지능 시스템의 형사책임 인정의 필요성과 가능성에 대하여 검토하고자 한다(Ⅲ.).

2) Stuart J. Russell/Peter Norvig, Artificial Intelligence: A Modern Approach, Pearson Education Limited, 2022, 1040면.

3) Russell/Norvig, 앞의 책, 1038-1040면.

4) Rebecca Crootof/Margot E. Kaminski/W. Nicholson Price, “Humans in the Loop”, Vanderbilt Law Review, Vol. 76 No. 2(2023), 500면.

5) 김난도, 트렌드 코리아 2026(미래의창, 2025), 135-136면.

6) “AI가 더 똑똑해질수록, 역설적으로 인간의 역할이 더 중요해진다.”(김난도, 앞의 책, 158면).

II. 휴먼인더루프 시스템에서 인공지능의 독자적인 형사책임의 인정 가능성

1. 휴먼인더루프의 의미와 규범적 검토 필요성

김난도 교수는 휴먼인더루프를 2026년의 핵심 트렌드의 하나로 소개한다. 그는 휴먼인더루프를 “인공지능이 업무를 수행하는 과정에 인간이 적어도 한 번은 개입해야 한다는 AI 활용 철학”⁷⁾이라고 표현한다. 이때의 “루프”란 “특정 업무의 처음부터 끝까지 이어지는 순환고리”를 말한다.⁸⁾ 요컨대, 인공지능의 업무 처리 과정에 인간이 최소한 한 번 이상 개입하여야 한다는 원칙이라고 할 수 있다.

김난도 교수는 인간과 인공지능의 협업방식을 ① 인간과 인공지능의 협업 방식인 휴먼인더루프(“협력형 · 공동 창작형 AI”) 이외에서도, ② 인간이 중심이 되고 인공지능이 보조 도구가 되는 방식[“AI인더루프(AI-in-the-loop, AITL)” 또는 “도구형 · 보조형 AI”] 그리고 ③ 인공지능이 중심이 되는 방식(“자동화형 · 대리 결정형 AI”) 등 3유형으로 나눈다. 세 번째 유형은 다시 (i) 인공지능이 작업을 수행하고 인간이 그 결과만을 감시하는 수동적 감시 시스템을 의미하는 “휴먼온더루프(Human-on-the-loop)”와 (ii) 인공지능이 최종 결정을 내리고 인간은 개입하지 않는 “휴먼아웃 오브더루프(Human-out-of-the-loop)”로 나눈다.⁹⁾

한편, 머신러닝(기계학습) 분야에서는 휴먼인더루프 머신러닝이 다루어지고 있다. 휴먼인더루프 머신러닝이란 “인공지능을 사용하는 애플리케이션에서 인간과 기계의 지능(intelligence)을 결합하는 일련의 전략”으로 정의되며, 머신러닝을 통해 의도하는 정확성과 효율성을 제고하는 것을 목표로 한다.¹⁰⁾ 이는 “인간과 기계 학습 알고리즘 사이의 새로운 유형의 상호 작용”으로 평가된다.¹¹⁾ 이와 유사하게 IBM은 휴먼인더루프를 “인간이 자동화 시스템의

7) 김난도, 앞의 책, 131면.

8) 김난도, 앞의 책, 132면. 휴먼인더루프는 “인공지능이 업무를 수행하는 과정에 인간이 의도적으로 개입하여 시스템의 정확성을 높이고, 최종 결정에 상황적 의미, 윤리적 판단, 창조적 감성을 부여함으로써 완성도를 높일 수 있는 업무 설계 철학”이라고 한다(같은 곳).

9) 김난도, 앞의 책, 138-149면.

10) Robert (Munro) Monarch, Human-in-the-Loop Machine Learning: Active learning and annotation for human-centered AI, Manning Publications, 2021, 4면.

운영, 감독, 의사 결정에 적극적으로 참여하는 시스템 또는 프로세스”로 정의하며, 인공지능의 맥락에서는 “정확성, 안전성, 책임성 또는 윤리적 의사 결정을 보장하기 위해 AI 워크플로에 인간이 관여”하는 것이라고 설명한다.¹²⁾

또한, 법률가인 크루토프/카민스키/프라이스(Crootof/Kaminski/Price)는 입법자의 규율 방식을 중심으로, 시스템보다는 인간에 초점이 맞추어 휴먼인더루프를 “알고리즘[인공지능]과 결합하여 이루어지는 단일하고 특정한 결정에 관여하는 개인”으로 정의한다.¹³⁾ 이들은 휴먼인더루프라고 하기 위해서는 (즉, 인간이 루프 ‘안’에 있다고 하기 위해서는) 인간이 시스템의 개별 결정에 대하여 개입(intervene), 변경(change), 승인(approve)하거나 또는 즉시 집행(immediately implement)할 수 있는 능력을 보유하여야 한다고 한다.¹⁴⁾

김난도 교수의 설명이 사회학적 차원의 것이라면, 머신러닝 분야의 설명은 공학적인 차원의 것이라 할 수 있다. 반면, 법률가인 크루토프 등의 정의는 원래의 공학적 의미와는 다소 거리가 있지만, 법적 책임이 귀속되는 주체를 명확하게 하기 위한 정의라고 할 수 있다.

법적 책임을 검토하기 위해서는, 위 크루토프 등의 논의와 같이 인공지능 시스템과 인간을 휴먼인더루프 시스템을 구성하는 두 가지 인자(因子)로 보면서, 휴먼인더루프는 그 시스템에 관여하는 인간으로 보는 것이 검토의 목

11) 고민수, “24. Human in the loop Machine Learning-한글”, The Universe of AI-한글, 최종 편집일시: 2026년 6월 13일, <<https://wikidocs.net/255177>>, 최종검색: 2026. 6. 18. 또한, 휴먼인더루프 머신러닝은 “인간 전문가는 데이터에 주석[annotation_필자]을 달고, 결과를 검증하는 등의 방법으로 AI 시스템에 감독과 지침을 제공하여 시스템이 지속적으로 학습하고 개선되도록 돕기 위한 것으로 “컴퓨터 비전[vision_필자] 분야”의 머신 러닝에서 채택되고 있다고 한다(같은 곳).

12) IBM, “휴먼 인 더 루프란 무엇인가요?”, <<https://www.ibm.com/kr-ko/think/topics/human-in-the-loop>>, 최종검색: 2026. 6. 15.

13) Crootof/Kaminski/Price, 앞의 글, 440면 및 432면 각주 1). 여기에서는, ① 의사결정자인 인간이 특정 사안에서 알고리즘 시스템을 사용할지 여부를 결정하는 경우(예컨대, 의사가 AI 진단 도구를 사용할지 여부를 선택하는 경우), ② 인간과 알고리즘이 작업을 서로 넘겨주거나 협력하여 수행하는 경우(예컨대, 비행기 조종사가 일부 작업은 수동으로 하면서 나머지는 자율 주행에 의존하는 경우), ③ 인간이 중간결정 단계(mid-determination)에서 알고리즘을 변경하는 경우(예컨대, 변호사가 e-디스커버리 도구의 검색 매개변수를 재설정하는 경우), ④ 알고리즘에 의해 도출된 결론을 실행할지 여부나 방법을 결정하는 경우(예컨대, 지휘관이 알고리즘이 추천한 목표물을 공격하지 않기로 결정하는 경우) 등을 예시하고 있다(같은 글, 440면).

14) Crootof/Kaminski/Price, 앞의 글, 441면. 크루토프 등도 이 용어의 시스템 관련성을 배제하지는 않는다. 즉, 휴먼인더루프 “시스템”을 “알고리즘의 의사결정 프로세스를 감독(oversee)하는” 휴먼인더루프 “시스템” 그리고 완전자동화 시스템과 같이 “인간의 개입(involve)이나 감독 없이 이루어지는 알고리즘 의사결정 프로세스”인 휴먼오프더루프(human-off-the-roof) “시스템”과 대비시킨다[같은 글, 434면 각주 11)].

적에 부합하고 내용도 간명할 것이다. 정리하자면, ‘휴먼인더루프’ 원칙이란 인공지능 시스템의 운영 과정에 인간이 반드시 개입하여야 한다는 원칙이다. 이 원칙에 따라 구성된 시스템이 휴먼인더루프 시스템이고, 이 시스템에 개입하는 인간은 휴먼인더루프이다.

이 글에 다루는 것은 휴먼인더루프 시스템에 개입하는 인간의 형사책임이다. 이는 휴먼인더루프 시스템의 다른 한 축인 인공지능 시스템의 독자적 형사책임 가능성과 연결되어 논의되어 왔다.

2. 인공지능의 독자적인 형사책임 인정에 관한 논의

가. ‘합리적 에이전트’로서 인공지능

휴먼인더루프 시스템의 첫 번째 인자(因子)는 인공지능 시스템이다. 인공지능의 의미에 대해서는 다양한 정의가 시도되고 있으나, 최근에는 인공지능을 ‘합리적 에이전트’(rational agent)로 보는 시각이 우세하다.¹⁵⁾

보통 ‘합리적 에이전트’로서 인공지능은 “최상의 산출을 내기 위해서 혹은 그것이 불명확한 경우, 예상되는 최상의 결과를 달성하기 위하여” “자율적으로 작동하면서, 자신의 환경을 인지하고, 장기간에 걸쳐 지속적으로 유지되며, 변화에 적응하고, 목표를 설정하여 추구하는” 존재라고 설명된다.¹⁶⁾ 여기에서 “에이전트”란 “센서(sensor)를 통해 외부 환경을 지각하고(percept), 액추에이터(actuator)를 통해 외부 환경에 대응하여 동작(act)할 수 있는 존재”를 의미한다.¹⁷⁾ 이러한 에이전트는 지각한 것을 행동으로 일대일 대응시켜(mapping) 구현하는 “에이전트 프로그램”(agent program)과 이 프로그램을 물

15) Russell/Norvig, 앞의 책, 19-22면. 이에 관한 국내 문헌으로는 주현경, “인공지능과 형사법의 쟁점—책임귀속을 중심으로—”, 형사정책, 제29권 제2호(한국형사정책학회, 2017), 9-10면; 오병두, “인공지능(AI)과 형사책임 -‘형사적인 것’의 탐구를 위한 문제 제기를 곁하여”, 홍익법학, 제26권 제4호(홍익대학교 법학연구소, 2025), 288-291면. 또한, 2025년 미국 라스베이거스에서 열린 CES 2025 이후 주목되고 있는 “피지컬 AI”(Physical AI)는 “현실 세계에서 물리적 행동을 수행하고 환경과 상호작용할 수 있는 AI”로 정의되는데(이재진/조상동, “현실세계와 상호작용하는 AI: 피지컬 AI의 기술발전 및 정책적 시사점”, 이슈페이퍼 및 정책연구, 제2025권 제4호(한국산업기술진흥원, 2025. 9), 1면). 이러한 ‘피지컬 AI’의 정의는 ‘합리적 에이전트’의 그것과 동일하다고 생각된다.

16) Russell/Norvig, 앞의 책, 21-22면. 이 정의를 따른 것으로는 주현경, 앞의 글, 10면; 허황, “인공지능과 형법상 행위론”, 법학연구, 제25권 제3호(한국법학회, 2025), 130면; 오병두, 앞의 글, 290-291면.

17) Russell/Norvig, 앞의 책, 54면. “수학적으로 말하자면, 에이전트의 행태(behavior)는 주어진 지각 시퀀스(percept sequence)를 동작으로 매핑하는 에이전트 함수로 묘사된다.”(같은 곳).

리적 센서와 액추에이터를 갖춘 컴퓨팅 장치에서 실행하는 “에이전트 아키텍처”(agent architecture)로 구성된다.¹⁸⁾ 여기에서 ‘합리적 에이전트’라고 하려면 설계자의 설계에서 벗어나 스스로 인식하고 학습절차를 통해 스스로 동작하는 자율성(autonomy)을 갖추어야 한다.¹⁹⁾

나. 인공지능과 관련한 형사책임 논의

인공지능과 관련한 형사책임 논의는 주로 인공지능 그 자체보다는 이를 물리적으로 구현하는 로봇(일종의 ‘합리적 에이전트’)을 중심으로 논의되어 왔다. 즉, 인공지능 로봇의 형사책임 논의는 ‘합리적 에이전트’가 초래한 ‘사태’를 인간의 ‘행위’와 동일시하기 위한 법적 논증과 결합하면서 발전하였다. 여기에서는 ‘합리적 에이전트’의 핵심적 개념요소인 ‘자율성’과 ‘행태’ 개념이 독자적인 형사책임을 인정하기 위한 전제로서 논의되고 있다.

(1) 인공지능의 ‘자율성’을 중심으로 하는 논의

인공지능의 정의로서 ‘합리적 에이전트’의 개념에는 이미 ‘자율성’이 내포되어 있다. 인공지능의 자율성은 보통 “외부적인 인간의 통제로부터 독립된 수준”²⁰⁾을 말한다. 인공지능 기술의 발전은 보통 그 자율성의 증가로 표현된다. 따라서 자율성의 수준의 강약에 의해²¹⁾ 그 법적 책임범위가 정해진다는 설명이 많이 이루어진다.²²⁾ 인공지능을 독자적인 책임 주체로 검토하기 위해서는 그 결정과 활동에서 스스로 의사를 결정할 수 있는 ‘자율성’이 긍정되어야 한다고 보기 때문이다.²³⁾

인공지능의 자율성 정도와 형사책임 논의는 ‘강한 인공지능’(Strong AI)과 ‘약한 인공지능’(Weak AI)의 구별론과 연결된다.²⁴⁾ 약한 인공지능의 경우,

18) Russell/Norvig, 앞의 책, 65면.

19) Russell/Norvig, 앞의 책, 60면.

20) 유럽연합 로보로(RoboLaw) 프로젝트의 입장이다. E. Palmerini/A. Bertolini/F. Battaglia/B.-J. Koops/A. Carnevale/P. Salvini, “RoboLaw: Towards a European Framework for Robotics Regulation”, Robotics and Autonomous Systems, Vol. 86(2016), 79면. 또한, Andreas Matthias, “The Responsibility Gap: Ascribing Responsibility for the Actions of Learning Automata”, Ethics and Information Technology, Vol. 6 No. 3(2004), 180면.

21) Palmerini 외, 앞의 보고서, 80면. 로보로 프로젝트를 소개하는 위 글에서는 ‘강한 자율성(Strong Autonomy)’과 ‘약한 자율성(Weak Autonomy)’으로 표현된다(같은 면).

22) 자율주행자동차나 의료로봇에 대하여 자율성 정도와 연결하여 형사책임 범위를 논하는 것이 그 예이다.

23) 양천수, “인공지능과 법적 인격—법적 인격의 인정 가능성과 필요성”, 한국포스트휴먼연구소 편, 가상인격: AI 시대, 인간의 인격을 묻다(파이돈, 2026)[이하 “앞의 글(1)”이라 한다], 280-281면.

배후에 있는 인간의 책임이 강조되면서 대체로 전통적인 형법이론에 따라 해결되어야 한다는 입장으로 귀일하고 있지만,²⁵⁾ 강한 인공지능의 경우에는 입장이 나뉜다.²⁶⁾ 강한 인공지능의 정의는 그 형사책임 주체성 논의와 관련이 깊다. 인공지능의 독자적인 형사책임 능력을 인정하는 견해는 그 수준을 높게 잡고 있지만, 구체적으로 여러 가지로 정의하고 있다. 즉, 독자적인 형사책임의 가능성이 인정하는 견해는 대체로 인간과 유사한 수준의 인공지능을 의미한다고 보지만, 나아가 ‘자아 인식’이 있는 인공지능,²⁷⁾ 일반인공지능(범용인공지능, Artificial General Intelligence, AGI)²⁸⁾이나 초인공지능(Artificial Super Intelligence, ASI)²⁹⁾ 등을 의미한다고 보기도 한다.

인공지능의 높은 자율성 논의는 그에 기초한 법적 ‘인격’을 인정할 수 있어서 독자적인 형사책임 주체성을 고려할 수 있다는 입장과도 연결된다.³⁰⁾ 예컨대, 인공지능에 ‘전자인격’(electronic personhood)이라는 ‘인격’을 부여할 수 있다거나,³¹⁾ 보다 일반적으로 ‘탈인간중심적 법이론’에 따라 법적 ‘인격’을 인정할 수 있다고 보는 견해³²⁾ 등은 대체로 형사책임 주체성에 대해 긍정적인 입장을 보인다.

24) 안성조, “인공지능 로봇의 형사책임 —논의방향의 설정에 관한 몇 가지 발전적 제언—”, 법철학연구, 제20권 제2호(한국법철학회, 2017), 77-122면; 양천수, “인공지능과 법체계의 변화: 형사사범을 예로 하여”, 법철학연구, 제20권 제2호(한국법철학회, 2017)[이하 ‘앞의 글(2)’이라 한다], 45-76면.

25) 예컨대, 안성조, 앞의 글, 101-104면.

26) 높은 자율성을 가진 강한 인공지능의 경우에는 독자적인 인격주체성을 인정할 수 있다는 입장으로는, 류화진, “지능형 로봇의 범죄주체성과 형사책임”, 과학기술과 법, 제7권 제2호(충북대학교 법학연구소, 2016), 235면; 윤영철, “인공지능 로봇의 형사책임과 형법의 ‘인격적 인간상’에 대한 고찰”, 원광법학, 제35권 제1호(원광대학교 법학연구소, 2019), 112면; 송승현, 앞의 글, 492-512면; 구길모/주현경, “인공지능과 형사법”, 한국인공지능법학회 편, 인공지능과 법(박영사, 2019), 162면.

27) 임석순, “형법상 인공지능의 책임귀속”, 형사정책연구, 제27권 제4호(한국형사법무정책연구원, 2016), 73면; 안정빈, “인공지능 로봇에 관한 형사책임 —인공지능형법에 의한 형사처벌가능성을 중심으로—”, 외법논집, 제46권 제4호(한국외국어대학교 법학연구소, 2022), 67-68면.

28) 고인석, “로봇이 책임과 권한의 주체일 수 있는가”, 철학논총, 제67집(세한철학회, 2012), 7면; 송승현, “트랜스휴먼 및 포스트휴먼 그리고 안드로이드(로봇)에 대한 형법상 범죄주체의 인정여부”, 홍익법학, 제17권 제3호(홍익대학교 법학연구소, 2016), 490면.

29) 양천수, 앞의 글(2), 49-51면.

30) 근대법에서 인격과 자율성의 관계에 관하여는 양천수, 앞의 글(1), 261-263면.

31) 김성돈, “전통적 형법이론에 대한 인공지능 기술의 도전”, 형사법연구, 제30권 제2호(한국형사법학회, 2018), 98면 이하; 전지연, “형법상 전자인(e-person)의 가능성”, 비교형사법연구, 제21권 제2호(한국비교형사법학회, 2019), 17면.

32) 양천수, 앞의 글(2), 66-68면; 전지연, 앞의 글, 17면.

(2) 인공지능의 ‘행태’를 중심으로 하는 논의

인공지능의 ‘행태’를 중심으로 하는 형사책임 논의는 ‘합리적 에이전트’에 관한 설명에서 등장하는 “행태”(‘행위’, behavior)라는 표현과 관계가 있다. 인공지능이 독자적인 형사책임의 주체가 될 수 있는지에 관한 논의는, 인공지능에 의해 초래된 외부적 변화를 ‘사태’(event)라고 할 때, 이러한 ‘사태’를 ‘합리적 에이전트’의 ‘행태’로 파악하여 인간의 ‘행태’와 동일시할 수 있음을 그 출발점으로 삼는다.³³⁾ 즉, ‘행태’개념을 통해 인간의 ‘행위’와 인공지능 로봇이 초래한 ‘사태’를 통일적으로 취급할 수 있다면, 범죄론체계의 검토를 거쳐 인공지능의 독자적인 형사책임을 인정할 수 있다는 논리구성을 취한다.

2010년대 독일에서 등장한 ‘로봇형법’(Strafrecht für Roboter) 이론³⁴⁾은 그 전형을 보여준다. ‘로봇형법’이론은 인공지능의 행위능력과 책임능력을 인간과 동일하게 인정할 수 있다고 주장한다. 인공지능 로봇이 초래한 ‘사태’를 인간의 ‘행위’와 같은 것으로 보아, 구성요건해당성, 위법성, 책임으로 이어지는 범죄론체계의 검토를 통과한다면 인공지능 로봇에 대하여 형사책임을 지울 수 있다고 한다.³⁵⁾ 이 ‘로봇형법’이론에 대해서는 독일과 한국 모두에서 비판적인 견해가 주류이다.³⁶⁾

형법계의 형법이론에서도 ‘로봇형법’이론과 유사한 논의가 있다. 범죄의 객관적 요소인 ‘범죄행위’[소위(所爲), actus reus]와 주관적 요소인 ‘범죄의사’[범의(犯意), mens rea]를 요구하는데, 인공지능 로봇의 움직임이 ‘범죄행위’에 해당하고, 그 의사결정의 자율성을 ‘범죄의사’로 볼 수 있다면 이를 범죄로 볼 수 있다는 입장이다.³⁷⁾

33) 이하에서는 논의의 명료화를 위하여, 원문 자체를 인용하는 경우가 아닌 한 ‘행태’개념을 인간의 ‘행위’와 인공지능 로봇의 ‘사태’로 나누어 서술하기로 한다. 인공지능이 초래하는 ‘사태’와 인간의 ‘행위’를 구별하는 설명으로는 오병두, 앞의 글, 292-294면.

34) 이 이론의 주창자는 잘 알려진 바와 같이, 에릭 힐겐도르프(Eric Hilgendorf) 교수이다. Eric Hilgendorf, “Können Roboter schuldhaft handeln?”, in: Susanne Beck (Hrsg.), *Jenseits von Mensch und Maschine: Ethische und rechtliche Fragen zum Umgang mit Robotern, Künstlicher Intelligenz und Cyborgs*(Nomos, 2012), 119-132면. 이에 대한 비판적인 연구로는 김영환, “로봇 형법(Strafrecht für Roboter)?”, *법철학연구*, 제19권 제3호(한국법철학회, 2016), 143-168면.

35) Hilgendorf, 앞의 글, 125-130면.

36) 독일의 논의에 관하여는 Sabine Gless/Emily Silverman/Thomas Weigend, “If Robots Cause Harm, Who Is to Blame? Self-Driving Cars and Criminal Liability”, *New Criminal Law Review: An International and Interdisciplinary Journal*, Vol.19, No.3(2016), 426-428면. 또한, 인공지능의 독자적인 형사책임 주체성을 비판하는 최근의 연구로는 김남훈/이경렬, “생성형 AI와 인간 행위자간 형사책임의 구성 방안”, *입법학연구*, 제22권 제2호(한국입법학회, 2025), 85-117면.

다. 인공지능의 독자적인 형사책임 논의와 휴먼인더루프 시스템

‘합리적 에이전트’로서 인공지능의 ‘자율성’과 ‘행태’를 중심으로 하는 형사책임 논의는 모두 인공지능이 초래한 외부적 ‘사태’가 인간의 ‘행위’와 유사함을 전제 또는 근거로 하는 논의이다. 현재로서는 인공지능 자체의 형사책임을 논하기 어렵다. 이는 입법을 통하지 않은 해석론만으로는 수용되기에는 한계가 있기 때문이다.

우선, 인간의 일정한 속성을 유비(類比)하여 인공지능 로봇의 ‘행위’로 인정함으로써 형사책임을 인정하는 것은 인간을 대상으로 입법된 형벌법규를 인공지능 로봇에 유추적용한다는 의심에서 자유롭기 어렵다. 다음으로, 인공지능에 대한 형사제재도 전통적인 형벌의 목적에 비추어 수용되기도 어렵다. 형벌을 통한 예방은 행위자나 다른 일반인이 형벌로 인하여 자신의 의사결정을 수정할 수 있음을 전제로 한다. 그러나 인공지능의 경우에는 스스로의 수정을 기대하기보다는 행정적 명령 등에 일률적인 수정조치 등이 더 효율적이고 더 현실적일 것이다. 또한, 인공지능 로봇이 초래한 사회적 해악에 대해서 로봇에게 응보(복수)한다는 관념은 아직 받아들이기 쉽지 않을 것이다.

정리하자면, 현 단계에서는 인공지능 로봇에 대해 독자적인 형사책임을 인정할 수 없다고 할 수 있다. 문제는 이러한 결론이 휴먼인더루프 시스템에서 인간의 형사책임 문제를 자동적으로 해결해주지 않는다는 점에 있다. 휴먼인더루프 시스템의 두 가지 구성요소(인자)인 인공지능 시스템과 인간의 역할 중에서, 일정한 자율성을 가진 인공지능 시스템에 대한 법적 평가를 도외시키고 인간만을 중심으로 형사책임을 논하기는 부적절한 특성이 있기 때문이다.

우선, 인간과 인공지능 시스템의 협업이 예정된 경우에도, 단순한 도구적 사용과 인공지능 시스템의 자율성에 기반한 활동은 구별될 수 있다. 인공지능의 높은 자율성은 인간의 상황에 대한 지배력을 그만큼 약화시키기 때문이다. 또한, 일상적인 인간만의 범죄에서 인간 개입에 대한 법적 비난의 기준(예컨대, 예견가능성, 인과관계, 책임귀속 등)을 휴먼인더루프 시스템에서 인간 개입의 경우에 그대로 적용하면, 그 비난이 과소하거나 과대하여 비례성을 상실할 수도 있다. 인공지능 시스템의 자율성 정도가 높을수록, 그리고 그에 따른 외부적 변화의 규모가 클수록, 이에 개입한 인간의 행위와 그 결

37) Gabriel Hallevy, “The Criminal Liability of Artificial Intelligence Entities - From Science Fiction to Legal Social Control”, Akron Intellectual Property Journal, Vol. 4 No. 2(2010), 171-202면. 할레비 이론에 대한 소개와 비판으로는 안성조, 앞의 글, 86-93면; 김남훈/이경렬, 앞의 글, 94-95면.

과가 행위불법과 결과불법 양 측면에서 불일치할 가능성이 커지기 때문이다.

이러한 맥락에서 인공지능 시스템과 인간의 상호작용에 따른 결과와 법적·사회적 책임의 관계를 규명함으로써 그에 상응하는 법적 규율의 필요성을 제시하는 논의로서 인공지능의 자율성 강화에 따른 “책임공백”(responsibility gap)론이 주목된다.

3. 휴먼인더루프 시스템과 ‘책임공백’의 문제

(1) 인공지능의 자율성과 ‘책임공백’의 문제

인공지능 또는 ‘합리적 에이전트’ 자체에 대한 법적 책임을 논해야 하는 이유로는 ‘책임공백’의 문제가 흔히 거론된다.³⁸⁾ 인공지능과 관련해서 이 논의를 처음 시도한 사람은 철학자인 안드레아스 마티아스(Andreas Matthias)이라고 한다.³⁹⁾ 마티아스는 인공지능의 자율성, 즉 머신러닝과 자율적 행동 능력으로 스스로 학습하는 기계는 최초의 시스템 설계자나 운영자가 더 이상 ‘통제’(control)할 수 없게 됨에 따라 책임을 질 사람이 없어지는 현상을 ‘책임공백’이라고 하였다.⁴⁰⁾

철학자 산토니 데 시오와 메카치(Santoni de Sio/Mecacci)는 이 개념을 더욱 발전시켜 4가지의 유형의 ‘책임공백’ 유형을 제시한다. 이들은 ① 마티아스가 지적하였던 ‘책임공백’, 즉 부정적 결과에 대하여 인공지능의 불투명성(black box)으로 인해 어떤 인간에게도 도덕적·법적 비난을 가할 수 없는 상태를 “법적 책임공백”(culpability gap)이라고 한다.⁴¹⁾ 여기에 더하여 ② 알고리즘과 인공지능의 설명 가능성(explainability)이 약화되면서 그에 기반한 자신의 선택과 행동에 대해서 설명하지 못하게 되는 “도덕적 책무성 공백”(moral accountability gap),⁴²⁾ ③ 공공기관의 결정이 인공지능을 기반으

38) ‘책임공백’에 관한 국내 논의로는 고인석, “전자인격이 책임공백 문제를 해결할 적절한 방안인가”, 철학·사상·문화, 제49권(동국대학교 동서사상연구소, 2025), 93-116면. 이 글은 아래 설명하는 ‘법적 책임공백’ 중에서 민사책임의 공백을 중심으로 다루고 있다.

39) 인공지능과 관련한 ‘책임공백’ 논의로 마티아스의 2004년 논문(Matthias, 앞의 글, 175-183면)이 최초의 것이라는 것으로는 Filippo Santoni de Sio/Giulio Mecacci, “Four Responsibility Gaps with Artificial Intelligence: Why They Matter and How to Address Them”, Philosophy & Technology, Vol. 34(2021), 1058면.

40) Matthias, 앞의 글, 177면.

41) Santoni de Sio/Mecacci, 앞의 글, 1060-1063면.

42) Santoni de Sio/Mecacci, 앞의 글, 1063-1065면. 의사가 자신이 사용한 인공지능 진단시스템에 따라 진단과 처방을 하면서도 인공지능의 불투명성과 복잡성으로 인해 그 정확한 진단 ‘논리’

로 이루어지면서 시민의 감시나 설명 요구에 의한 민주적 통제가 어려워지는 “공적 책무성 공백”(public accountability gap),⁴³⁾ ④ 높은 안전기준을 제 공할 법적 의무와 기업의 사회적 책임(corporate social responsibility, CSR) 등과 같이 장래를 향하여 개선해가는 “능동적 책임공백”(active responsibility gap)을 제시한다. 여기에서 ‘능동적 책임공백’은 인공지능 설계자, 제조자나 운영자 등에 대하여 사회적, 법적 비난이 차단됨으로써 하여 그들의 도덕적 해이 또는 법률적 무관심을 유발하는 경우의 책임공백을 지칭한다.

(2) 인공지능의 자율성과 휴먼인더루프 시스템

보통 ‘책임공백’론은 인공지능에 독자적인 형사책임 능력을 부여할 경우, 관련자(개발자, 운영자, 소유자, 이용자 등)의 책임이 정범의 책임에서 공범의 책임으로 약화되거나 차단된다는 점을 지적하며, 인공지능의 독자적인 형사책임을 인정할 필요성을 옹호하는 차원에서 주장된다. 다른 차원에서 보면, ‘책임공백’론은 단순히 법적 책임을 지을 주체가 불분명해진다는 문제점을 제시하는 데에 그치지 않고, 인공지능과 관련하여 규율이 요구되는 범위가 기존 실정법 적용상의 흠결부분을 넘어 사회 전반에 미치며 민주적 통제, 정책적 규율에까지 확장되어야 함을 조명해준다. 특히 ‘능동적 책임공백’의 경우, 인공지능의 개발, 판매, 관리 등과 관련된 인간과 기업 등의 책임 문제에 대해 기존과 다른 접근이 필요함을 시사한다. 요컨대, ‘책임공백’론은 인공지능의 법적 책임이 문제되는 영역에서 법적 통제의 필요성과 그 근거를 제시한다는 점에서 주목할 필요가 있다.

이러한 ‘책임 공백’에 대응하기 위한 방안 중 하나로, ‘인간의 관리·감독’과 같은 인간의 개입을 강조하는 것이 휴먼인더루프 시스템이다. 휴먼인더루프 시스템에서도 인간은 법적 책임으로부터 완전히 자유롭지 않지만, 그와 동시에 인공지능 시스템의 활용이 단순한 도구적 이용과는 다르다는 점에서 기존과는 다른 법적 고려가 필요하다. 즉, 휴먼인더루프 시스템에서 인공지능 시스템에 대해 독자적이고 배타적인 형사책임을 인정하는 것은 관여한 인간의 ‘책임공백’의 문제를 야기하여, 인공지능 시스템 내에 인간의 역할을 부여한 취지에 반한다. 반대로, 휴먼인더루프 시스템에서 인공지능 시스템의

를 제대로 이해하지 못하는 경우를 대표적인 예로 든다(같은 글, 1065면).

43) Santoni de Sio/Mecacci, 앞의 글, 1065-1066면. 능동적 책임은 과거의 잘못을 반성한다는 의미의 ‘소극적 책임’을 구성하는 법적 책임, 도덕적 책무성, 공적 책무성과 구별된다(같은 곳).

역할을 무시하고 인간만의 책임으로 다루는 것은, 자율성을 갖춘 인공지능 시스템의 결정과 집행을 전적으로 인간의 ‘작품’으로 돌리는 결과가 되어 부당하다. 요컨대, 휴먼인더루프 시스템에서 인간의 형사책임은 인간을 주체로 하는 형법이론 그 자체를 중심으로 접근하면서도 ‘협업’의 시스템의 다른 인자(因子)인 인공지능 시스템의 역할을 함께 고려하여야 한다고 할 수 있다.

III. 휴먼인더루프 시스템에서 인간의 형사책임

1. 휴먼인더루프 시스템과 관련한 규제 입법상의 책임

가. 최근의 인공지능 입법

휴먼인더루프 시스템은 인공지능 시스템의 작동과정에 인간이 관여한다는 점을 핵심으로 한다. 이러한 요소는 최근의 인공지능 입법인 유럽연합의 인공지능법(Artificial Intelligence Act, 이하 “인공지능법”이라 한다)⁴⁴⁾과 「인공지능 발전과 신뢰 기반 조성 등에 관한 기본법」⁴⁵⁾(이하 “인공지능기본법”이라 한다)에 상당 부분 반영되어 있다.

(1) 유럽연합의 인공지능법

2024년 7월 12일에 통과된 유럽연합의 인공지능법은 최초의 인공지능 관련 입법이다.⁴⁶⁾ 인공지능법은 ‘인공지능’(AI)과 ‘인공지능 시스템’(AI system)을 구별하는데, 이때의 인공지능 시스템은 앞에서 검토한 ‘합리적 에이전트’의 의미로 이해된다.

내용적으로는 인공지능 시스템의 개발자와 배포·운영자(deployer)에 대한 규제를 규정하며, ‘위험’ 개념에 기초한 “위험 기반 접근법”(risk-based approach)에 따라 인공지능을 규제한다.⁴⁷⁾ 인공지능법에서 “위험”(risk)이란 “해악의

44) REGULATION (EU) 2024/1689 OF THE EUROPEAN PARLIAMENT AND OF THE COUNCIL (Artificial Intelligence Act), 2024. 7. 12, <<https://eur-lex.europa.eu/eli/reg/2024/1689/oj/eng>>, 최종검색: 2026. 6. 15.

45) 법률 제20676호. 최종개정: 법률 제21311호, 2026. 1. 20.

46) 인공지능법은 “인간 중심적이고 신뢰할 수 있는 인공지능”의 도입을 촉진하고, 인공지능 시스템(AI system)의 개발, 출시, 서비스제공 및 이용에 관한 통일적인 법적 틀을 제공함으로써, 건강, 안전, 기본권의 보장 수준을 제고하며, 유럽연합 내의 인공지능 기술의 혁신을 지원할 것을 목적으로 한다[서문(1)].

발생 확률과 그 해악의 심각성의 조합”으로 정의된다(제3조 제2항). 인공지능법은 이를 인공지능 시스템의 위험을 전면 금지되는 “수용불가 위험”(unacceptable risk), 적법요건을 따라야 하는 “고위험”(high risk), 투명성의무가 강조되는 “제한된 위험”(limited risk), “최소 위험”(minimal risk)의 네 등급으로 분류하고, 각 등급에 따라 규제를 차등화하고 있다.⁴⁸⁾

인공지능법은 인공지능 시스템이 인간의 건강·보건, 안전 또는 기본적인 권에 심각한 위험을 초래할 수 있는 분야를 고위험 분야로 분류하며(제6조), 고위험 분야로는 생체인증 등 8개의 주요 분야를 열거하고 있다[부속서(Annex) III].⁴⁹⁾ 인공지능법은 고위험 인공지능 시스템이 시장에 제공되기 전에 이행해야 할 엄격한 의무조항을 두면서, 이를 적법요건(requirement)으로 규정한다(제8조부터 제27조까지).⁵⁰⁾ 특히 사람의 감독(human oversight)을 적법요건의 하나로 규정하면서 “고위험 인공지능 시스템은, 적절한 인간-기계의 인터페이스 툴을 포함하여, 사용 기간 동안 인간(natural person)이 효율적으로 감독할 수 있는 방식으로 설계되고 개발되어야 한다”(제14조 제1항)고 명시하고 있다.

인공지능 시스템에 관한 규범 위반의 제재로 제재금(administrative fine)을 부과한다(제99조).⁵¹⁾ 제재금은 관련규정의 위반을 “수용불가 위험”과 관련하여 금지되는 인공지능 시스템의 경우(제99조 제3항)와 기타의 경우(같은 조 제4항)를 나누어 차등적으로 규정하여⁵²⁾ 그 실효성을 담보하고 있다.⁵³⁾

(2) 한국의 인공지능기본법

2025년 1월 21일 제정된 인공지능기본법은 국가 단위에서 이루어진 독립

47) European Commission, “AI Act”, (last update: 11 May 2026), <<https://digital-strategy.ec.europa.eu/en/policies/regulatory-framework-ai>>, 최종검색: 2026. 6. 15. 또한, 라기원, 유럽연합 인공지능법(EU AI ACT)의 특성과 쟁점 - 우리나라 인공지능 입법에 대한 시사, AI 이슈페이퍼(한국법제연구원, 2024. 5.), 12면 이하.

48) 인공지능법은 범용인공지능(General-Purpose AI)에 대해서도 규정하고 있다(chapter V).

49) 부속서(Annex) III에서 정하는 고위험 인공지능 시스템은 생체인증(biometrics), 필수적 사회기반시설(critical infrastructure), 교육 및 직업 훈련, 고용·채용 및 선발, 필수적 공·사 서비스, 법집행, 이민·망명 및 국경통제·관리, 사법 및 민주적 절차(선거) 등 8개 분야이다.

50) 이에 관한 상세한 설명은 라기원, 앞의 이슈페이퍼, 17면 이하.

51) 그밖의 제재수단으로 회원국 시장감독기관의 CE 마크 미부착이나 EU 데이터베이스 미등록에 대한 시정명령(제83조)이 있다.

52) 인공지능법은 기업의 경우 전자는 전 세계를 상대로 한 적전 회계연도 전세계 총 연간 매출액의 최대 7% 또는 최대 3,500만 유로(한화 약 500억 원) 중 큰 금액을, 후자는 최대 3% 또는 최대 15,000,000 유로(한화 약 220억 원) 중에서 큰 금액을 부과할 수 있도록 한다.

53) 인공지능법의 제제가 실효적이라는 것으로는 박세영, 앞의 글, 50면.

적인 인공지능 입법으로는 세계 최초의 것이다.⁵⁴⁾ 인공지능기본법은 ‘인공지능’과 ‘인공지능시스템’(제2조 제1호·제2호)을 나누는데, 이때의 ‘인공지능시스템’도 유럽연합의 인공지능법과 마찬가지로, ‘합리적 에이전트’의 의미로 이해된다.

인공지능법은 내용적으로 “고영향 인공지능”(제2조 제4호)과 “생성형 인공지능”(제2조 제5호)을 주된 규제대상으로 한다. 여기에서 “고영향 인공지능”이란, “사람의 생명, 신체의 안전 및 기본권에 중대한 영향을 미치거나 위험을 초래할 우려가 있는” 에너지, 먹는 물, 보건의료 체계, 의료기기, 원자력 시설, 생체인식정보, 채용·대출심사 등 일정한 범위의 “인공지능시스템”(제2조 제4호)을 말한다. 인공지능기본법 제34조 제1항 제4호는 “사람의 관리·감독”을 인공지능시스템을 개발·이용하거나 그 서비스를 제공하는 “인공지능사업자”에게 요구하고 있다.

인공지능기본법은 고영향 및 생성형 인공지능 투명성 확보를 위한 사전조치의 의무(제31조 제1항), 외국 인공지능사업자의 국내대리인 지정의무(제36조 제1항), 인공지능기본법 위반 인공지능사업자에 대한 위반행위의 중지·시정명령(제40조 제3항) 등의 불이행 조치의 경우에 “3천만원 이하의 과태료”에 처할 수 있도록 하고 있다(제43조). 행정제재 중심의 입법을 취하여, 인공지능기본법의 위반을 이유로 인공지능사업자에게 형벌을 과하는 규정을 두고 있지 않다.⁵⁵⁾

나. 최근의 인공지능 입법과 휴먼인터루프 시스템 규율의 한계

최근의 인공지능 입법은 고위험 또는 고영향 인공지능 영역에서 통제와 감독의 주체로서 인간의 역할을 강조하고 있다. 이는 휴먼인터루프 원칙을 담고 있다고 할 수 있다. 나아가 인공지능 입법은 고위험 또는 고영향 인공지능 시스템에 대한 인간의 개입 및 통제·관리의무를 강화하면서 행정적인 제재로 그 실효성을 담보하고 있다. 인공지능기본법의 경우 그 제재의 실효성이 낮아서 이를 보다 강화할 필요가 있다고 지적되고 있다.⁵⁶⁾ 그러한 제재

54) 인공지능기본법은 “인공지능의 건전한 발전과 신뢰 기반 조성에 필요한 기본적인 사항을 규정함으로써 국민의 권익과 존엄성을 보호하고 국민의 삶의 질 향상과 국가경쟁력을 강화하는 데 이바지함을 목적으로 한다”(제1조).

55) 인공지능기본법 제42조에서는 형벌을 규정하고 있으나, 국가인공지능전략위원회 위원회의 직무상 비밀누설죄를 정하고 있어서 인공지능 시스템과는 관련이 없다.

56) 김남훈/이경렬, 앞의 글, 104-106면; 박세영, 앞의 글, 51면.

의 하나로서 휴먼인더루프 시스템에서 일정한 역할을 수행하는 인간에 대한 형사책임도 논의되고 있다.

2. 휴먼인더루프 시스템과 인간의 형사책임

가. 휴먼인더루프 시스템에 관여한 인간의 형사책임 논의의 한계

휴먼인더루프 시스템에서 인간의 개입유형과 정도 등과 관련하여, 김난도 교수는 인간의 역할을 “업무의 성격에 따라” ① “규칙을 설정하고 질문을 수행하여 명령을 내”리는 ‘명령자’, ② “AI 학습에 사용되는 데이터에 편향이나 오류가 없는지 검토하고 수정”하는 ‘검증자’, ③ AI가 만들어낸 “결과물을 완결해주는 역할” 하는 ‘완결자’ 등으로 구별한다.⁵⁷⁾

이상과 같은 휴먼인더루프 시스템에서 인간 역할의 구분론은 법적인 책임을 묻는 단계에서는 보다 규범적인 접근이 필요하다. 이때 휴먼인더루프 시스템을 구성하는 인공지능 시스템과 인간 중에서 형사책임과 직결되는 것은 일차적으로 인간(‘휴먼’인더루프)라고 할 수 있다.

현재의 논의도 일차적으로 휴먼인더루프 시스템에 관여한 인간의 형사책임 위주로 구성되어 있다. 인간의 죄책을 과실범 또는 간접정범으로 검토하는 견해가 대표적이다.⁵⁸⁾ 첫째, 인공지능기본법이 고영향 인공지능에 대하여 정한 특정한 의무를 위반한 결과로 인명피해가 발생한 경우, 업무상과실치사상죄(형법 제268조)에서의 ‘업무상 주의의무’를 인정할 수 있다는 주장(과실책임론)이 있다.⁵⁹⁾ 둘째, 인공지능의 완전한 자율성을 전제로 인공지능의 ‘정보 내지 상황 인식 부재’를 이용한 인간에 대하여 간접정범의 성립 가능성을 인정할 수 있다는 주장(간접책임책임론)도 있다.⁶⁰⁾

전자인 과실책임론은 인공지능 시스템이 초래한 결과에 대한 인간의 예견가능성만을 근거로 형사 불법 행위의 양과 질을 판단한다. 인공지능의 자율성이 커질수록 인간의 주의 능력은 축소되기 때문에, 인간의 책임이 지나치

57) 김난도, 앞의 책, 144-149면.

58) 인공지능 로봇의 배후자의 형사책임을 사안에 따라 간접정범(“해커가 인공지능을 해킹하여 범죄를 저지르게 한 경우” 또는 “인공지능 소유 및 관리자가 인공지능에게 명령하여 범죄를 저지른 경우”)과 과실범(“인공지능 소유 및 관리자가 인공지능에게 명령하여 범죄를 저지른 경우”)의 경우로 나누어 이원상, 앞의 글, 465-467면.

59) 예컨대, 김남훈/이경렬, 앞의 글, 103-104면. 같은 취지: 박세영, 앞의 글, 54면.

60) 예컨대, 장하경/이경렬, “의료 인공지능 자율성에 따른 형사책임 귀속 연구”, 법학연구, 제28권 제3호(인하대학교 법학연구소, 2025), 336-338면(완전 자율형 의료 로봇을 전제로 하는 논의이다).

게 경감되거나 반대로 인공지능 시스템이 초래한 중대한 결과만으로 인간이 과도하게 포괄적인 형사책임을 부담할 위험이 있다.

반면, 후자인 간접정범책임론은 인공지능의 완전한 자율성을 전제로 하여, 인공지능 시스템을 인간과 유사한 ‘처벌받지 않는 도구’로 보고 배후자의 책임을 논하자는 입장이다. 이는 인공지능 로봇이 단순한 기계적 도구를 넘어 처벌받지 않는 실행자가 될 수 있음을 전제로 한다. 이 입장은 완전한 자율성을 갖춘 로봇을 전제로 하는데, 인공지능 로봇의 형사책임을 부정하면서도 관여자인 인간에 대해 직접정범이 아닌 간접정범의 죄책을 물어야 하는 이유가 먼저 설명되어야 성립 가능한 주장이다.

이상의 논의는 전통적인 형법이론 안에서 인공지능 시스템이 초래한 ‘사태’에 직·간접적으로 관여한 인간의 책임을 묻는 시도이다. 기본적으로 인공지능 시스템 자체가 사회적으로 유해한 형사불법(특히, 결과불법)을 초래함을 전제로 한다. 그러나 휴먼인더루프 시스템에서 인간은 상당한 자율성을 갖춘 인공지능 시스템과 협업하는 것이므로, 이는 인간과 인간의 협력과 다르고 인간이 단순한 도구를 이용한 경우와도 구별된다. 이러한 사정은 상당한 자율성을 갖춘 인공지능 시스템과 인간이 협업하는 구조인 휴먼인더루프 시스템에서 인간의 형사책임 문제를 현재의 형법해석을 통해서서는 대응하기 쉽지 않다는 점을 보여준다.

나. 휴먼인더루프 시스템과 관련한 새로운 형사입법의 가능성과 필요성

형법의 해석을 통하여 휴먼인더루프 시스템에서 인간의 형사책임 문제에 대한 효과적인 접근이 어렵다고 할 때, 다음으로 고려될 수 있는 것은 입법적인 접근이다.

입법적인 접근으로서, 우선 생각할 수 있는 것은 휴먼인더루프 시스템에 개입하는 인간의 주의의무와 그에 대한 책임, 즉 ‘인간의 감독 의무’라는 새로운 법적 책무를 법 개정을 통해 부과하거나 강화하는 방법이다. 그러나 아무리 입법이라고 해도 행위형법의 원칙과 책임주의의 관점에서 무한정 책임의 정도와 양을 높일 수는 없다. 게다가 인간에 대한 형사제재만으로 실효성을 담보하려는 시도는 휴먼인더루프 시스템의 특성이 비추어 한계가 있다.⁶¹⁾

다음으로, 입법을 통해 보통의 경우와 구별되는 특별한 형벌법규를 두는

61) “인공지능에 대하여 가능한 조치의 종류와 내용에 대하여는 별도의 논의가 필요하다”는 지적으로는 황만성, “인공지능의 형사책임에 관한 소고”, 법과정책, 제24권 제1호(제주대학교 법과정책연구원, 2018), 381면.

방식을 생각해볼 수 있다. 이와 관련해서는 기존의 연구에서 다양한 제안이 나와 있다. 우선, 인공지능에 대하여 양벌규정을 통한 형사처벌이 제안되고 있다.⁶²⁾ 현재 법인이나 사업주에 대한 형사책임 부과 방식으로 현행 법제가 취하는 방식으로 규율방식에 유사성이 있음을 근거로 하는 논의이다. 다음으로, 인공지능의 형사책임과 관련하여 미국의 ‘엄격책임’(strict liability) 제도를 도입하자는 제안도 있다.⁶³⁾ 엄격책임 제도는 주관적 요건(mens rea) 없이도 법정 의무 위반 자체로 제재하는 형사처벌 유형이며, 일반적인 형사범죄보다 경미한 불법에 한하여 인정된다.⁶⁴⁾ 인공지능 시스템의 제조·운용을 하는 배후의 기업에 대하여 실효적 형사제재를 가할 필요가 있다는 점을 근거로 한다.⁶⁵⁾

입법기술적인 접근을 제안하는 견해는 대체로 현재의 형법이론이 대처하기 어려운 분야를 규율하기 위해, 인간을 중심으로 하는 핵심형법과는 구별되는 영역을 설정하여 새로운 법익 침해상황에 대처한다는 취지를 담고 있다. 양벌규정 도입론은 행위자를 전제로 하여 수범자를 확대하는 것이므로 인공지능 시스템과 인간 중에서 누가 일차적인 행위자인가를 확정해야 한다는 점에서, 엄격책임 도입론은 주관적 요건 없는 형사제재를 인정하여야 한다는 점에서 아쉬움이 있는 접근이다. 여기에서 이러한 제안과 유사한 취지를 담고 있으면서, 보다 일반화된 접근이 있어 주목된다. 즉, 사회변화에 따라 새롭게 법익보호의 요청이 커지면서 새로이 형사제재가 도입되는 분야, 즉 환경형법, 경제형법 등 이른바 ‘현대적 형법’에 대하여 대안적 형사제재로서 “개입법”(Interventionsrecht)의 도입을 적극 고려해야 한다는 빈프리트 하세머(Hassemer)의 제안이 그것이다.⁶⁶⁾ 이러한 ‘개입법’은 —한국의 경범죄

62) 황만성, 앞의 글, 373면; 박광민/백민제, “인공지능 로봇의 범죄주체성과 형사책임의 귀속”, 법학연구, 제20집 제4호(인하대학교 법학연구소, 2017), 165-167면.

63) 이혜진, “미국 형법상 엄격책임의 이론과 현대적 전개: 인공지능 시대 자율주행기술에 대한 적용 가능성을 중심으로”, 동아법학, 제110호(동아대학교 법학연구소, 2026), 242면. 이 견해는 자율주행자동차 제조사에 “기업 보호관찰과 구조적 갱생”을 도입하는 것이 실효적 제재가 될 것이라고 한다(같은 글, 257-258면).

64) Wayne R. LaFave, LaFave's Principles of Criminal Law, 3th ed., West Academic, 2017, § 4.5(c)(216면). 일반범죄가 아닌 “공공 불법행위”(public tort), “공공복지범죄”(public welfare offense), “민사범죄”(civil offense) 등의 경우에 적용된다(같은 곳).

65) 이혜진, 앞의 글, 241면.

66) Winfried Hassemer, “Kennzeichen und Krisen des modernen Strafrechts”, Zeitschrift für Rechtspolitik, 25. Jahrg. H. 10(C.H. Beck, 1992), 383면. 하세머의 이러한 제안은 법익보호를 이유로 ‘현대화된 형법’을 이유로 과잉범죄화된 독일형법을 ‘핵심형법’(Kernstrafrecht)으로 축소하고 그 범위에서 엄격한 법치국가적 형법과 형사절차를 보장하고자 하는 취지에서 나온 것

처벌법이나 행정형법에 대응하는 제재인— 질서위반행위 규제법(Recht der Ordnungswidrigkeiten)과 형사법의 중간에, 그리고 민법과 공법의 중간에 위치하는 제재법이다. ‘개입법’은 형법에 비해서 유연하면서도 포괄적인 문언이 허용되고 상대적으로 완화된 형사절차에 의한 제재 부과가 가능한 대신, 그 제재의 정도를 낮춘 법률을 지칭한다. 하세머는 이러한 ‘개입법’이 “규범적으로 문제가 더 적을 뿐만 아니라, 현대 사회의 구체적인 문제를 실질적으로 해결하는 데에도 더 적합할 것”이라고 한다.⁶⁷⁾

하세머의 ‘개입법’적 접근은 휴먼인더루프 시스템에서 인간의 개입 양상에 따라 사안에 적합한 책임귀속 모델로 발전시킬 잠재성이 큰 발상이다. 인공지능 시스템과 관련한 ‘책임공백’ 상황, 휴먼인더루프 시스템에서 인간 개입의 양상, 그리고 인공지능이 초래하는 ‘사태’에 대한 법적 평가(예컨대, 행위불법과 결과불법의 괴리)를 반영하기 위해서는 이를 적극적으로 고려할 필요가 있다. 이때 ‘개입법’의 제재 대상에는 휴먼인더루프 시스템의 두 가지 인자인 인간과 인공지능 시스템 모두가 포함될 수 있다. 이를 위해 인공지능 자체의 형사책임 능력을 인간으로부터 유추할 필요가 없다는 점에서도 ‘개입법’은 매력적인 접근이다.⁶⁸⁾

IV. 맺으며

인공지능은 환경을 인지하고 목표를 추구하는 ‘합리적 에이전트’로서 자율성을 가지며, 외부 세계에 실질적인 변화를 초래한다. 특히 생성형 인공지능의 확산으로 환각 및 편향 문제가 빈번해짐에 따라, 업무 처리 과정에 인간이 개입하여 정확성과 윤리성을 확보해야 한다는 ‘휴먼인더루프’의 중요성이 더욱 부각되고 있다. 이미 유럽연합 인공지능법과 한국의 인공지능기본법은 고위험 또는 고영향 인공지능 시스템에 대해 인간의 감독을 핵심적 적법 요건으로 명문화함으로써, 이러한 요청을 법제적으로 뒷받침하고 있다.

휴먼인더루프 시스템에 관여한 인간은 자신의 관여 양상과 통제 가능성에

이다(같은 곳).

67) Hassemer, 앞의 글, 383면.

68) ‘개입법’적 접근에 따른 형사제재에 관하여는 지면 관계상 이 글에서 충분히 다루지 못하였다. 가까운 시일 내에 후속연구를 진행하고자 한다.

상응하여 책임을 부담하는 것이 원칙이며, 인공지능의 독자적 책임 인정 여부와 무관하게 시스템에 관여한 인간의 책임은 유지되어야 한다. 과실범 이론이나 간접정범 모델은 여전히 중요한 해석 틀이 될 것이지만, 인공지능의 자율성으로 인해 휴먼인더루프 시스템에 관여하는 인간의 형사책임을 충분히 반영하기 어렵거나 경우에 따라 그 제재가 실효성이 떨어지는 경우도 있을 수 있다. 따라서 휴먼인더루프 시스템과 관련한 인간의 형사책임은 인간의 개입 구조와 감독 의무를 중심으로 재구성될 필요가 있다. 이를 위해서는 전통적인 형벌 체계와 행정적 규제 사이의 중간 영역에서 실효적인 대응을 가능하게 하는 ‘개입법’적 접근을 입법적으로 구체화할 필요가 있다.

주제어 : 인공지능, 휴먼인더루프, 책임공백, 형사책임, 개입법

Keyword : Artificial Intelligence(AI), Human-in-the-Loop(HITL), Criminal Responsibility, Responsibility Gap, Interventionsrecht (Intervention Law)

투고일 : 2026. 7. 5. / 심사개시일: 2026. 7. 8. / 게재확정일: 2026. 7. 16.

[참고문헌]

- 김난도, 트렌드 코리아 2026, 미래의창, 2025.
- 라기원, 유럽연합 인공지능법(EU AI ACT)의 특성과 쟁점 - 우리나라 인공지능 입법에 대한 시사, AI 이슈페이퍼, 한국법제연구원, 2024. 5.
- Robert (Munro) Monarch, Human-in-the-Loop Machine Learning: Active learning and annotation for human-centered AI, Manning Publications, 2021.
- Stuart J. Russell/Peter Norvig, Artificial Intelligence: A Modern Approach, Pearson Education Limited, 2022.
- Wayne R. LaFave, LaFave's Principles of Criminal Law, 3th ed., West Academic, 2017.
- 고인석, “로봇이 책임과 권한의 주체일 수 있는가”, 철학논총, 제67집(새한철학회, 2012), 3-21면.
- , “전자인격이 책임공백 문제를 해결할 적절한 방안인가”, 철학·사상·문화, 제49권(동국대학교 동서사상연구소, 2025), 93-116면.
- 구길모/주현경, “인공지능과 형사법”, 한국인공지능법학회 편, 인공지능과 법(박영사, 2019), 152-165면.
- 김남훈/이경렬, “생성형 AI와 인간 행위자간 형사책임의 구성 방안”, 입법학연구, 제22권 제2호(한국입법학회, 2025), 85-117면.
- 김성돈, “전통적 형법이론에 대한 인공지능 기술의 도전”, 형사법연구, 제30권 제2호(한국형사법학회, 2018), 81-116면.
- 김영환, “로봇 형법(Strafrecht für Roboter)?”, 법철학연구, 제19권 제3호(한국법철학회, 2016), 143-168면.
- 김유근, “기업의 형사법적 책임: 책임귀속상의 문제점”, 한양법학, 제43집(한양법학회, 2013), 59-93면.
- 류화진, “지능형 로봇의 범죄주체성과 형사책임”, 과학기술과 법, 제7권 제2호(충북대학교 법학연구소, 2016), 213-242면.
- 박광민/백민제, “인공지능 로봇의 범죄주체성과 형사책임의 귀속”, 법학연구, 제20집 제4호(인하대학교 법학연구소, 2017), 153-178면.
- 박세영, “인공지능의 형법적 통제에 관한 고찰 -인공지능기본법을 중심으로-”, 입법학연구, 제22권 제1호(한국입법학회, 2025), 33-60면.
- 송승현, “트랜스휴먼 및 포스트휴먼 그리고 안드로이드(로봇)에 대한 형법상 범죄

- 주체의 인정여부”, *홍익법학*, 제17권 제3호(홍익대학교 법학연구소, 2016), 475-527면.
- 안성조, “인공지능 로봇의 형사책임 —논의방향의 설정에 관한 몇 가지 발전적 제언—”, *법철학연구*, 제20권 제2호(한국법철학회, 2017), 77-122면.
- 안정빈, “인공지능 로봇에 관한 형사책임 —인공지능형법에 의한 형사처벌가능성을 중심으로—”, *외법논집*, 제46권 제4호(한국외국어대학교 법학연구소, 2022), 63-86면.
- 양천수, “인공지능과 법적 인격—법적 인격의 인정 가능성과 필요성”, *한국포스트휴먼연구소 편, 가상인격: AI 시대, 인간의 인격을 묻다*(파이돈, 2026), 257-292면.
- , “인공지능과 법체계의 변화: 형사사법을 예로 하여”, *법철학연구*, 제20권 제2호(한국법철학회, 2017), 45-76면.
- 오병두, “인공지능(AI)과 형사책임 -‘형사적인 것’의 탐구를 위한 문제 제기를 겸하여”, *홍익법학*, 제26권 제4호(홍익대학교 법학연구소, 2025), 285-312면.
- 윤영철, “인공지능 로봇의 형사책임과 형법의 ‘인격적 인간상’에 대한 고찰”, *원광법학*, 제35권 제1호(원광대학교 법학연구소, 2019), 95-123면.
- 이원상, “인공지능 대응에 있어 형사법 이론의 한계”, *형사법의 신동향*, 제59호(대검찰청, 2018), 444-475면.
- 이재진/조상동, “현실세계와 상호작용하는 AI: 피지컬 AI의 기술발전 및 정책적 시사점”, *이슈페이퍼 및 정책연구*, 제2025권 제4호(한국산업기술진흥원, 2025. 9).
- 이형석, “피지컬 AI의 행위자성 및 헌법적 책임귀속 구조의 재구성에 관한 소고”, *법학논총*, 제46권 제2호(전남대학교 법학연구소, 2026), 1-38면.
- 이혜진, “미국 형법상 엄격책임의 이론과 현대적 전개: 인공지능 시대 자율주행기술에 대한 적용 가능성을 중심으로”, *동아법학*, 제110호(동아대학교 법학연구소, 2026), 239-266면.
- 임석순, “형법상 인공지능의 책임귀속”, *형사정책연구*, 제27권 제4호(한국형사법무정책연구원, 2016), 1-23면.
- 장하경/이경렬, “의료 인공지능 자율성에 따른 형사책임 귀속 연구”, *법학연구*, 제28권 제3호(인하대학교 법학연구소, 2025), 307-344면.
- 전지연, “형법상 전자인(e-person)의 가능성”, *비교형사법연구*, 제21권 제2호(한국비교형사법학회, 2019), 1-28면.

- 허 황, “인공지능과 형법상 행위론”, 법학연구, 제25권 제3호(한국법학회, 2025), 127-152면.
- 황만성, “인공지능의 형사책임에 관한 소고”, 법과정책, 제24권 제1호(제주대학교 법과정책연구원, 2018), 361-384면.
- Andreas Matthias, “The Responsibility Gap: Ascribing Responsibility for the Actions of Learning Automata”, Ethics and Information Technology, Vol. 6 No. 3(2004), 175-183면.
- E. Palmerini/A. Bertolini/F. Battaglia/B.-J. Koops/A. Carnevale/P. Salvini, “RoboLaw: Towards a European Framework for Robotics Regulation”, Robotics and Autonomous Systems, Vol. 86(2016), 78-85면.
- Eric Hilgendorf, “Können Roboter schuldhaft handeln?”, in: Susanne Beck (Hrsg.), Jenseits von Mensch und Maschine: Ethische und rechtliche Fragen zum Umgang mit Robotern, Künstlicher Intelligenz und Cyborgs(Nomos, 2012), 119-132면.
- Filippo Santoni de Sio/Giulio Mecacci, “Four Responsibility Gaps with Artificial Intelligence: Why They Matter and How to Address Them”, Philosophy & Technology, Vol. 34(2021), 1057-1084면.
- Gabriel Hallevy, “The Criminal Liability of Artificial Intelligence Entities - From Science Fiction to Legal Social Control”, Akron Intellectual Property Journal, Vol. 4 No. 2(2010), 171-202면.
- Rebecca Crootof/Margot E. Kaminski/W. Nicholson Price, “Humans in the Loop”, Vanderbilt Law Review, Vol. 76 No. 2(2023), 429-510면.
- Sabine Gless/Emily Silverman/Thomas Weigend, “If Robots Cause Harm, Who Is to Blame? Self-Driving Cars and Criminal Liability”, New Criminal Law Review: An International and Interdisciplinary Journal, Vol.19, No.3(2016), 412-436면.
- Winfried Hassemer, “Kennzeichen und Krisen des modernen Strafrechts”, Zeitschrift für Rechtspolitik, 25. Jahrg. H. 10(C.H. Beck, 1992), 378-383면.
- 고민수, “24. Human in the loop Machine Learning-한글”, The Universe of AI-한글, 최종 편집일시: 2026년 6월 13일, <<https://wikidocs.net/255177>>, 최종검색: 2026. 6. 18.
- IBM, “휴먼 인 더 루프란 무엇인가요?”, <<https://www.ibm.com/kr-ko/think/topics/>>

human-in-the-loop>, 최종검색: 2026. 6. 15.

REGULATION (EU) 2024/1689 OF THE EUROPEAN PARLIAMENT AND OF THE COUNCIL (Artificial Intelligence Act), 2024. 7. 12, <<https://eur-lex.europa.eu/eli/reg/2024/1689/oj/eng>>, 최종검색: 2026. 6. 15.

European Commission, “AI Act”, (last update: 11 May 2026), <<https://digital-strategy.ec.europa.eu/en/policies/regulatory-framework-ai>>, 최종검색: 2026. 6. 15.

[국문초록]

‘휴먼인더루프(Human-in-the-Loop, HITL)’ 원칙이란 인공지능 시스템의 운영 과정에 인간이 반드시 개입하여야 한다는 원칙이다. 인공지능의 자율성이 증가할수록 그로 인하여 발생하는 결과에 대한 법적, 도덕적 책임 주체가 불명확해지는 ‘책임공백’이 심화된다. 휴먼인더루프 원칙은 인간의 감독을 강화함으로써 이러한 공백을 구조적으로 예방할 것을 강조한다.

휴먼인더루프 시스템으로 인하여 초래된 사회적 해악에 관여한 인간은 자신의 관여 형태와 정도에 따라 형사책임을 부담하는 것이 원칙이다. 문제는 그 책임범위와 정도를 판단하기 쉽지 않다는 점에 있다. 휴먼인더루프 시스템에서는 인간과 인공지능 시스템의 협업을 전제로 인간의 개입 방식 그리고 인공지능 시스템의 작동 방식에 상응하는 책임 귀속 구조가 요구된다. 이를 위해 전통적인 형벌 체계와 행정적 제재 사이의 중간 영역에서 실효적인 규제가 가능한 제재 모델이 필요하다. 이를 위해 빈프리트 하세머(Winfried Hassemer)가 제안한 ‘개입법’(Interventionsrecht)과 같은 완화된 형사책임 모델의 도입을 고려할 필요가 있다.

[Abstract]

Human-in-the-Loop Systems and Criminal Responsibility

Oh, Byung Doo*

The Human-in-the-Loop (HITL) principle requires meaningful human oversight and intervention across the design, deployment, and operation of artificial intelligence (AI) systems. As AI systems attain higher levels of autonomy, the so-called “responsibility gap”—in which legal and moral accountability for harmful outcomes becomes diffuse or indeterminate—tends to widen. The HITL principle seeks to mitigate this gap by securing effective and continuous human control throughout the AI decision-making processes.

Within the HITL framework, individuals involved in the development, deployment, or operation of AI systems that cause harm should, in principle, bear criminal liability commensurate with the nature and extent of their involvement. The central difficulty, however, lies in delineating the proper scope and limits of such liability. Because HITL systems are inherently structured around human - AI collaboration, the attribution of criminal responsibility must account for both the form and degree of human intervention and the operational characteristics, including the level of autonomy, of the AI system. In this respect, there is a compelling need for an intermediate sanctioning model capable of addressing behavior that gives rise to risks falling between traditional criminal law and administrative regulation. A particularly promising approach is a mitigated model of criminal liability inspired by Winfried Hassemer’s concept of Interventionsrecht (Intervention Law), which offers a normative framework for responding to risks that cannot be adequately managed through either conventional criminal sanctions or administrative measures alone.

* Ph.D. in Law, Professor, College of Law, Hongik University

